Tarefa 1 - Aprendizado de máquina

Designing Machine Learning Systems - cap 1-5

Emelyn Clementino Freire

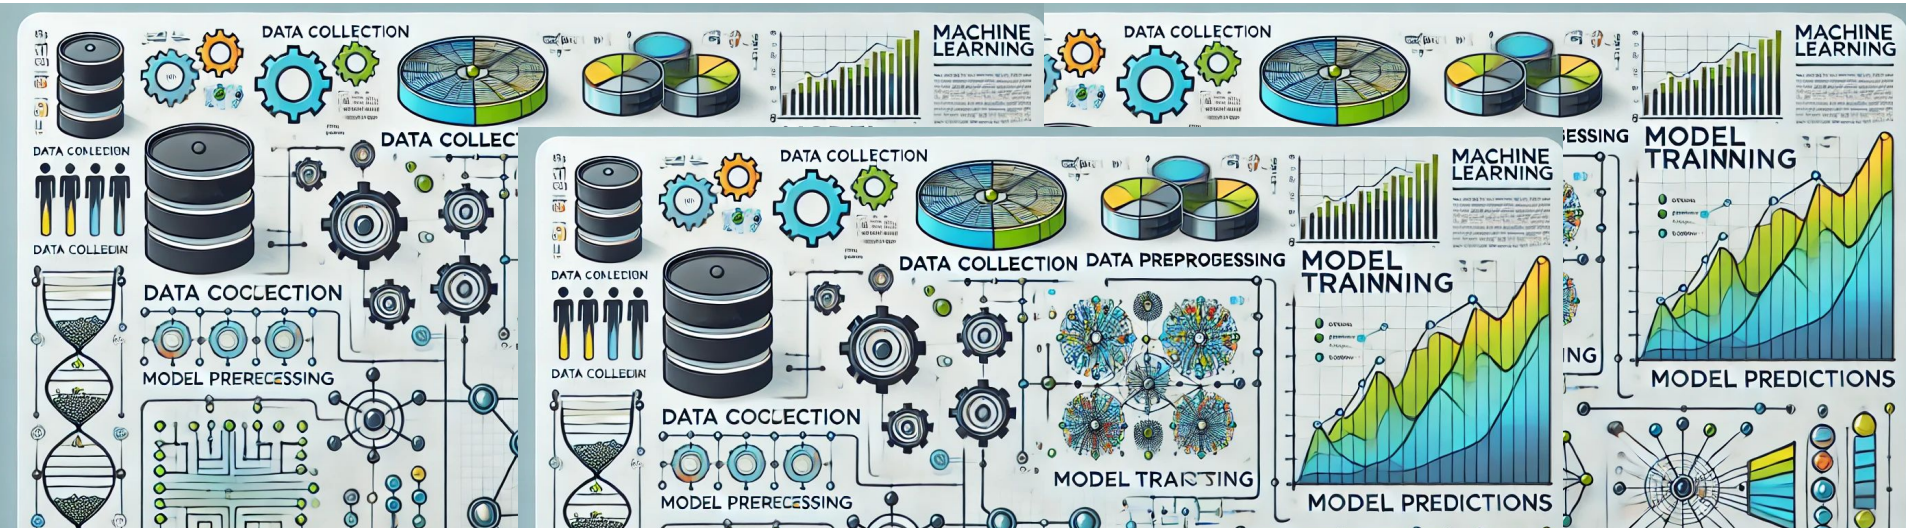

O'REILLY

Designing Machine Learning Systems

An Iterative Process for Production-Ready Applications

Chip Huyen

Capítulo 1: Overview of Machine Learning Systems

Objetivo:

Explicar o que são sistemas de aprendizado de máquina (ML) e como eles são usados.

Principais pontos:

- **Quando usar ML:**
  - Para identificar padrões complexos nos dados.
  - Para fazer previsões, como recomendar filmes ou prever o clima.
  - Para lidar com grandes volumes de informações.
- **Como funciona um sistema de ML:**
  - É mais do que só o algoritmo: inclui dados, infraestrutura e como tudo isso se conecta para resolver problemas reais.
- **Desafios:**
  - Um sistema de ML precisa ser rápido, confiável e atender às necessidades de quem vai usá-lo.

```python
# Capítulo 1: Overview of Machine Learning Systems
print("### Capítulo 1: Overview of Machine Learning Systems ###")
# Exemplo de quando usar ML: Classificação binária simples
X, y = make_classification(n_samples=500, n_features=5, random_state=42)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# Treinamento simples de modelo
model = LogisticRegression()
model.fit(X_train, y_train)

# Previsões e avaliação
predictions = model.predict(X_test)
print("\nRelatório de Classificação:\n")
print(classification_report(y_test, predictions))

# Visualização simples
plt.scatter(X_test[:, 0], X_test[:, 1], c=predictions, cmap='viridis', alpha=0.5)
plt.title("Classificação: Previsões de Teste")
plt.show()
```

```
### Capítulo 1: Overview of Machine Learning Systems ###

Relatório de Classificação:

              precision    recall  f1-score   support

           0       0.89      0.91      0.90        75
           1       0.91      0.89      0.90        75

    accuracy                           0.90       150
   macro avg       0.90      0.90      0.90       150
weighted avg       0.90      0.90      0.90       150
```

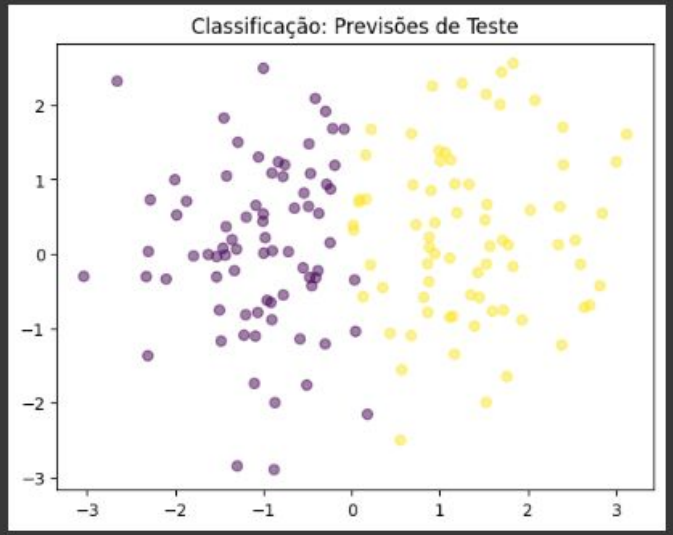

Capítulo 2: Introduction to Machine Learning Systems Design

Objetivo:

Apresentar como planejar sistemas de ML que sejam confiáveis, eficientes e fáceis de ajustar.

Principais pontos:

- **Começando pelo objetivo:**
  - Entender o que o negócio precisa e alinhar isso com o que o sistema de ML deve fazer.
  - Definir métricas claras para medir o sucesso.
- **O que faz um bom sistema:**
  - **Confiabilidade:** Funciona bem sem falhas.
  - **Escalabilidade:** Aguenta crescer junto com o aumento de dados ou usuários.
  - **Manutenção:** Fácil de atualizar e monitorar.
- **Como fazer:**
  - Seguir um processo de tentativa e erro: definir problemas, testar soluções, avaliar e melhorar.

```python
# Capítulo 2: Introduction to Machine Learning Systems Design
print("### Capítulo 2: Introduction to Machine Learning Systems Design ###")
# Demonstração de confiabilidade e escalabilidade
print("Simulação de análise de desempenho em diferentes tamanhos de amostras")
sizes = [100, 500, 1000, 5000]
latencies = []

for size in sizes:
    X_sample, y_sample = make_classification(n_samples=size, n_features=5, random_state=42)
    model = LogisticRegression()
    %time model.fit(X_sample, y_sample)
    latencies.append(size / model.n_iter_[-1])

plt.plot(sizes, latencies, marker='o')
plt.xlabel("Tamanho do conjunto de dados")
plt.ylabel("Desempenho (amostras por iteração)")
plt.title("Escalabilidade do Modelo")
plt.show()
```

```
### Capítulo 2: Introduction to Machine Learning Systems Design ###
Simulação de análise de desempenho em diferentes tamanhos de amostras
CPU times: user 6.03 ms, sys: 0 ns, total: 6.03 ms
Wall time: 6.05 ms
CPU times: user 4.44 ms, sys: 0 ns, total: 4.44 ms
Wall time: 4.46 ms
CPU times: user 4.16 ms, sys: 0 ns, total: 4.16 ms
Wall time: 4.22 ms
CPU times: user 8.11 ms, sys: 7.92 ms, total: 16 ms
Wall time: 12.3 ms
```

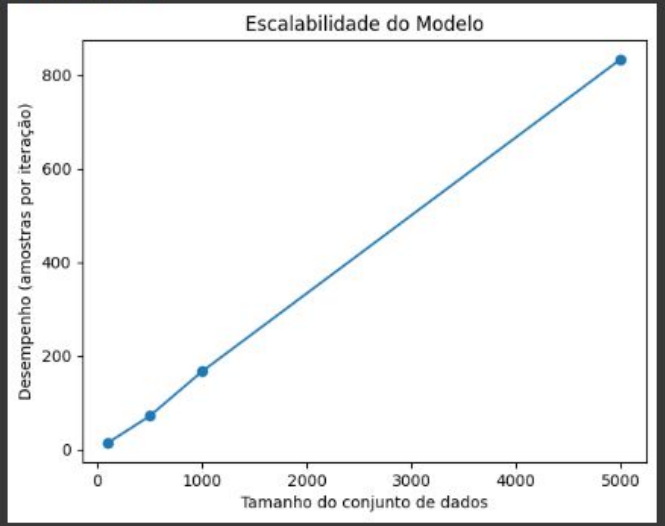

Capítulo 3: Data Engineering Fundamentals

Objetivo:

Mostrar como organizar e processar dados para que o sistema de ML funcione bem.

Principais pontos:

- **De onde vêm os dados:**
  - Podem ser organizados em tabelas (dados estruturados) ou mais livres, como texto e imagens (não estruturados).
- **Como organizar os dados:**
  - Usar bancos de dados relacionais (como tabelas) ou NoSQL para casos mais flexíveis.
- **Transformando dados em algo útil:**
  - Usar processos como ETL (Extrair, Transformar, Carregar) para preparar os dados.
- **Desafios:**
  - Garantir que os dados sejam confiáveis, atualizados e possam ser usados em larga escala.

```python
# Capítulo 3: Data Engineering Fundamentals
print("### Capítulo 3: Data Engineering Fundamentals ###")
# Exemplo de preparação de dados: Limpeza e transformação
raw_data = {'idade': [23, 35, np.nan, 29], 'salario': [50000, 70000, 80000, np.nan]}
data = pd.DataFrame(raw_data)
print("Dados Brutos:\n", data)
data.fillna(data.mean(), inplace=True)
data['salario_escalonado'] = StandardScaler().fit_transform(data[['salario']])
print("Dados Pós-Limpeza:\n", data)
```

```
### Capítulo 3: Data Engineering Fundamentals ###
Dados Brutos:
    idade  salario
0   23.0  50000.0
1   35.0  70000.0
2    NaN  80000.0
3   29.0      NaN
Dados Pós-Limpeza:
    idade       salario  salario_escalonado
0   23.0  50000.000000           -1.543033
1   35.0  70000.000000            0.308607
2   29.0  80000.000000            1.234427
3   29.0  66666.666667            0.000000
```

Capítulo 4: Training Data

Objetivo:

Ensinar como escolher, preparar e melhorar os dados usados para

"treinar" o sistema de ML.

Principais pontos:

- **Escolher bem os dados:**
  - Garantir que eles sejam representativos do problema que você quer resolver.
- **Rotular os dados:**
  - Identificar o que cada dado representa, como classificar imagens em “gato” ou “cachorro”.
- **Lidando com problemas comuns:**
  - Resolver casos de desbalanceamento, como quando temos muitas imagens de um tipo e poucas de outro.
- **Aumentando os dados:**
  - Criar variações dos dados, como ajustar cores de uma imagem ou girá-la.

```python
# Capítulo 4: Training Data
print("### Capítulo 4: Training Data ###")
# Exemplo de balanceamento de classes
imbalanced_y = [0] * 95 + [1] * 5
plt.bar([0, 1], [imbalanced_y.count(0), imbalanced_y.count(1)], color=['blue', 'orange'])
plt.title("Distribuição de Classes Desequilibrada")
plt.show()

balanced_y = np.random.choice([0, 1], size=100, p=[0.5, 0.5])
plt.bar([0, 1], [list(balanced_y).count(0), list(balanced_y).count(1)], color=['blue', 'orange'])
plt.title("Distribuição de Classes Balanceada")
plt.show()
```

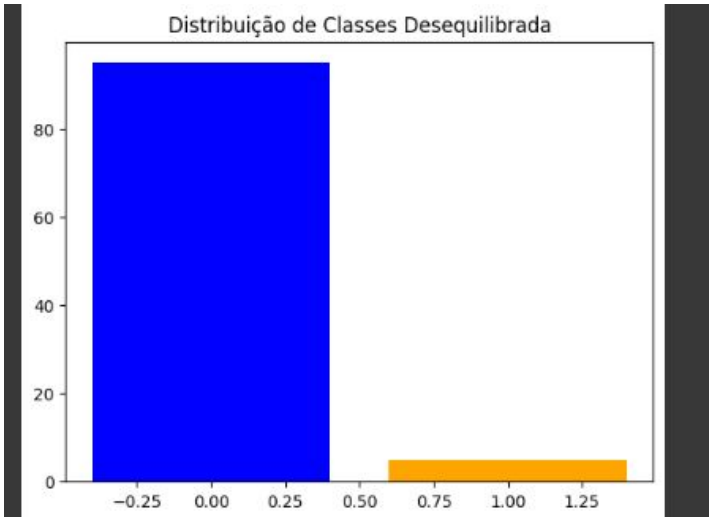

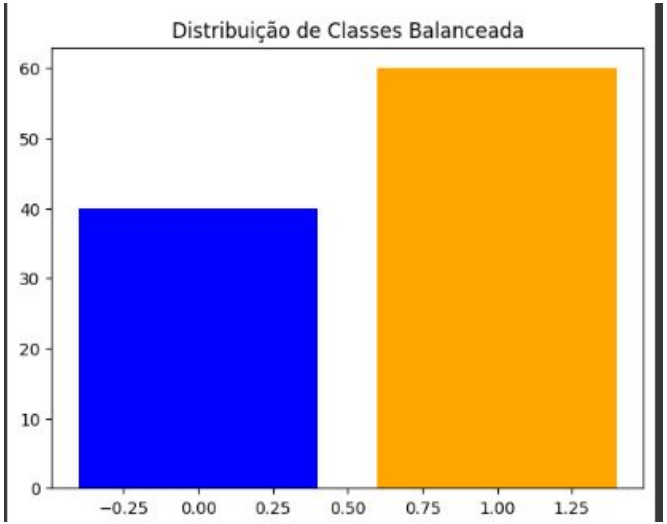

Capítulo 5: Feature Engineering

Objetivo:

Ensinar como extrair informações importantes dos dados para que o sistema funcione melhor.

Principais pontos:

- **O que são features:**
  - São características dos dados que ajudam o modelo a aprender, como o tamanho ou a cor de um objeto em uma imagem.
- **Como melhorar os dados:**
  - Preencher valores faltantes, ajustar os dados para ficarem na mesma escala e transformar textos em números.
- **Evitar erros:**
  - Garantir que o modelo só use informações que ele realmente terá quando estiver funcionando.
- **Generalização:**
  - Criar features que funcionem bem com novos dados, não apenas com os dados usados no treinamento.

```python
# Capítulo 5: Feature Engineering
print("### Capítulo 5: Feature Engineering ###")
# Exemplo de criação de features
raw_features = pd.DataFrame({
    'idade': [23, 45, 31],
    'salario': [50000, 80000, 60000]
})
raw_features['idade_quadrado'] = raw_features['idade'] ** 2
raw_features['salario_log'] = np.log(raw_features['salario'])
print("Dados com Novas Features:\n", raw_features)
```

```
### Capítulo 5: Feature Engineering ###
Dados com Novas Features:
    idade  salario  idade_quadrado  salario_log
0      23    50000             529    10.819778
1      45    80000            2025    11.289782
2      31    60000             961    11.002100
```